Deep learning and inverse problems **Exercise 8**:

## **Problem 1.1**

$$\frac{1}{2} \|Ax - y\|_{2}^{2} + \lambda \cdot \frac{1}{2} \|x\|_{2}^{2}$$

$$= \frac{1}{2} (Ax - y)^{T} (Ax - y) + \lambda \cdot \frac{1}{2} \cdot x^{T} \cdot x$$

$$= \frac{1}{2} \cdot x^{T} A^{T} A \times - \frac{1}{2} \cdot x^{T} A^{T} y - \frac{1}{2} \cdot y^{T} A \times + \frac{1}{2} y^{T} y + \frac{1}{2} \cdot \lambda x^{T} x$$

$$\frac{1}{2} \|Ax - y\|_{2}^{2} + \lambda \cdot \frac{1}{2} \|x\|_{2}^{2}$$

$$= A^{T} A \times - \frac{1}{2} \cdot A^{T} y - \frac{1}{2} \cdot A^{T} y$$

$$\stackrel{!}{=} 0 \qquad \text{minimize it.}$$

$$\Rightarrow (A^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (A^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (A^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

$$\Rightarrow (X^{T} A + \lambda I) \cdot x = A^{T} y.$$

## Problem 1.2

$$\begin{split} &\|\hat{\chi}_{2,\lambda}\left(\mathsf{A}\times+\mathsf{e}\right)-\mathsf{x}\|_{2}^{2} \\ &=\|V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\Sigma^{\mathsf{T}}\mathsf{U}^{\mathsf{T}}\cdot(\mathsf{A}\times+\mathsf{e})-\mathsf{x}\|_{2}^{2} \\ &=\|V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\Sigma^{\mathsf{T}}\mathsf{U}^{\mathsf{T}}\cdot(\mathsf{U}\Sigma\mathsf{V}^{\mathsf{T}}\times+\mathsf{e})-\mathsf{x}\|_{2}^{2} \\ &=\|V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\Sigma^{\mathsf{T}}\mathsf{E}\mathsf{V}^{\mathsf{T}}\mathsf{x}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\Sigma^{\mathsf{T}}\mathsf{U}^{\mathsf{T}}\mathsf{e}-\mathsf{x}\|_{2}^{2} \\ &=\|V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\Sigma^{\mathsf{T}}\mathsf{E}\mathsf{V}^{\mathsf{T}}\mathsf{x}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}\mathsf{V}^{\mathsf{T}}\mathsf{x}-V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}\mathsf{V}^{\mathsf{T}}\mathsf{x}\\ &+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\Sigma^{\mathsf{T}}\mathsf{U}^{\mathsf{T}}\mathsf{e}-\mathsf{x}\|_{2}^{2} \\ &=\|V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})\mathsf{V}^{\mathsf{T}}\mathsf{x}-V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}\mathsf{V}^{\mathsf{T}}\mathsf{x}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\Sigma^{\mathsf{T}}\mathsf{U}^{\mathsf{T}}\mathsf{e}-\mathsf{x}\|_{2}^{2} \\ &=\|V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})\mathsf{V}^{\mathsf{T}}\mathsf{x}-V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}\mathsf{V}^{\mathsf{T}}\mathsf{x}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\Sigma^{\mathsf{T}}\mathsf{U}^{\mathsf{T}}\mathsf{e}-\mathsf{x}\|_{2}^{2} \\ &=\|V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})\mathsf{V}^{\mathsf{T}}\mathsf{x}-V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}\mathsf{V}^{\mathsf{T}}\mathsf{x}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\Sigma^{\mathsf{T}}\mathsf{U}^{\mathsf{T}}\mathsf{e}-\mathsf{x}\|_{2}^{2} \\ &=\|V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})\mathsf{V}^{\mathsf{T}}\mathsf{x}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}\mathsf{V}^{\mathsf{T}}\mathsf{x}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}^{\mathsf{T}}\mathsf{v}^{\mathsf{T}}\mathsf{x}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}^{\mathsf{T}}\mathsf{v}^{\mathsf{T}}\mathsf{x}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}^{\mathsf{T}}\mathsf{v}^{\mathsf{T}}\mathsf{x}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}^{\mathsf{T}}\mathsf{v}^{\mathsf{T}}\mathsf{x}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}^{\mathsf{T}}\mathsf{v}^{\mathsf{T}}\mathsf{v}^{\mathsf{T}}\mathsf{v}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}^{\mathsf{T}}\mathsf{v}^{\mathsf{T}}\mathsf{v}+V\cdot(\Sigma^{\mathsf{T}}\Sigma+\lambda\mathsf{I})^{-1}\cdot\lambda\mathsf{I}^{\mathsf{T}}\mathsf{v}^{\mathsf{T}}$$

$$V \cdot (\Sigma^{T}\Sigma + \lambda I)^{-1} \cdot \Sigma^{T} U^{T} e$$

$$= V \cdot \left[ \begin{array}{c} 61 & 62 \dots & 6m \\ \hline & 0 \\ \hline & & \\ \end{array} \right] \cdot \begin{bmatrix} 67 & 62 \dots & 6m \\ \hline & & \\ \end{array} \right] \cdot \begin{bmatrix} 67 & 62 \dots & 6m \\ \hline & & \\ \end{array} \right] \cdot \begin{bmatrix} 67 & 62 \dots & 6m \\ \hline & & \\ \end{array} \right] \cdot \begin{bmatrix} 61 & 62 \dots & 6m \\ \hline & & \\ \end{array} \right] \cdot U^{T} \cdot e$$

$$= V \cdot \begin{bmatrix} \frac{\delta I}{\delta I^{2} + \lambda} & \frac{\delta I}{\delta I^{2} + \lambda} & \dots & \frac{\delta I}{\delta I^{2} + \lambda} \\ \hline & & \\ \end{array} \right] \cdot U^{T} \cdot e \quad Similar \text{ to the worst-case example}$$

$$\text{in lecture, a form of "SVD".}$$

 $\Rightarrow$  the worst-case perturbation is  $\hat{e}=e$ . Umin, umin is the left singular vector of A corresponding to the smallest singular value.

$$\|\widehat{x}_{2,\lambda}(Ax+e) - x\|_{2}$$

$$= \|V \cdot (\Sigma^{T}\Sigma + \lambda I)^{-1} \cdot (\Sigma^{T}U^{T}e - \lambda I)^{T} \cdot (\Sigma^{T}U^{T}e - \lambda I)^{T}$$

$$\frac{\text{Volthogonal suntary}}{\text{II}} \quad || \quad (\Sigma^T \Sigma + \lambda I)^{-1} \cdot (\Sigma^T U^T e - \lambda I \cdot V^T x) ||_{2}^{2}$$

$$= \left\| \begin{bmatrix} \frac{0}{0} \\ \vdots \\ \frac{\delta \min}{\delta \min_{i} n + \lambda} \end{bmatrix} \right\|_{2}^{2} + \left\| \begin{bmatrix} \frac{\delta_{1} + \delta_{1}^{2} \lambda + \lambda^{2}}{\delta_{1}^{2} + \lambda} & \frac{\delta_{2} + \delta_{2}^{2} \lambda + \lambda^{2}}{\delta_{2}^{2} + \lambda} & \frac{\delta \min_{i} + \delta \min_{i} \lambda + \lambda^{2}}{\delta \min_{i} + \lambda} \end{bmatrix} \right\|_{2}^{2}$$

when a increases, the reconstruction error decreases.

```
In [1]: import numpy as np
          from tadm import tadm
          import matplotlib.pyplot as plt
          from sklearn.metrics import mean_squared_error
          def soft thresholding(z, lambd):
              Soft-thresholding operator.
              :param z: The input.
:param lambd: The hyperparameter controls the soft-thresholding operator.
               :return: The result of soft-thresholding.
              return np.multiply(np.sign(z), np.maximum(np.abs(z) - lambd, 0))
          def g_function(A, x, y, lambd):
              The objective function that to be minimized (least-squares regression problem with 11-norm regularization)
               :param A: The measurement matrix.
               :param x: The sparse vector at iteration k.
               :param y: The measurement.
               :param lambd: The hyperparameter controls the soft-thresholding operator.
              :return: The result of the objective function.
              return 0.5 * np.linalg.norm(A @ x - y, ord=2) ** 2 + lambd * np.linalg.norm(x, ord=1)
          def ISTA(A, y, lambd, tol):
              Iterated Soft Thresholding Algorithm (ISTA).
               :param A: The measurement matrix.
               :param y: The measurement.
               :param lambd: The hyperparameter controls the soft-thresholding operator.
              :param tol: The stopping criterion.
              return: The solution of the sparse vector, a list of iteration numbers, and a list of g_function results.
              dim_x = np.shape(A)[1]
L = np.linalg.norm(A) ** 2 # Lipschitz const
              # Initialization
              step size = 1 / L
              step_size = 1 / I

# x_k = np.random.normal(0, 1, siz

x_k = np.zeros((dim_x, 1))

g_k = g_function(A, x_k, y, lambd)

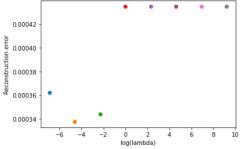
ite_k = 1

diff = 1000
                     = np.random.normal(0, 1, size=(dim_x, 1))
               # Loop
              while abs(diff) > tol:
    gradient_k = A.T @ A @ x_k - A.T @ y
    z_k = x_k - step_size * gradient_k
                   x_k_plus_one = soft_thresholding(z_k, lambd / L)
g_k_plus_one = g_function(A, x_k_plus_one, y, lambd)
                   diff = g_k_plus_one - g_k
                   ite_k += 1
                   x_k = x_k_plus_one
              g_k = g_k_plus_one
x_final = x_k_plus_one
              return x final
          # Parameter
          space_lambd = [1e-3, 1e-2, 1e-1, 1, 1e1, 1e2, 1e3, 1e4]
          # A: Gaussian mean 0, variance 1/500
          A = np.random.normal(0, np.sqrt(1/500), size=(500, 2000))
          # x: 50-sparse with mean 0, variance 1/50
          x = np.random.normal(0, np.sqrt(1/50), size=(2000, 1))
          zero_indices = np.random.choice(np.arange(2000), replace=False, size=int(1950))
          x[zero_indices] = 0
          # e: mean 0, variance 0.5/500
          e = np.random.normal(0, np.sqrt(0.5/500), size=(500, 1))
         # y
y = A @ x + e
          # Grid search for different sparsity values
          space_sparsity = [50]
search_shape = [len(space_sparsity), len(space_lambd)]
          mse = np.zeros(search_shape)
          i = 0
          \dot{1} = 0
          for sparsity in space_sparsity:
              for lambd in tqdm(space_lambd):
    x_final = ISTA(A, y, lambd, tol)
                   mse[i, j] = mean_squared_error(x_final, x)
              j += 1
i += 1
```

100%

| 8/8 [00:44<00:00, 5.50s/it]

```
In [3]: plt.xlabel('log(lambda)')
  plt.ylabel('Reconstruction error')
  plt.plot(np.log(lambda_new), mse, marker="o")
  plt.show()
```



In [ ]: